



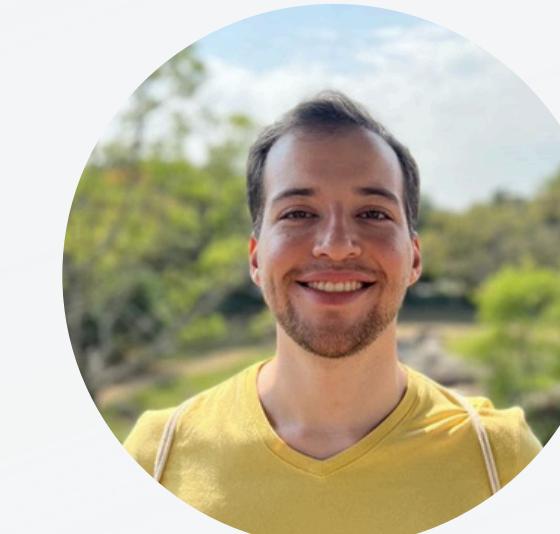
RECONHECIMENTO DE GÊNERO MUSICAL



EQUIPE



Geovana Teixeira



Jair Martins



Lídia do Vale



Mirmila Sócrates



Natã Milhomem

INTRODUÇÃO

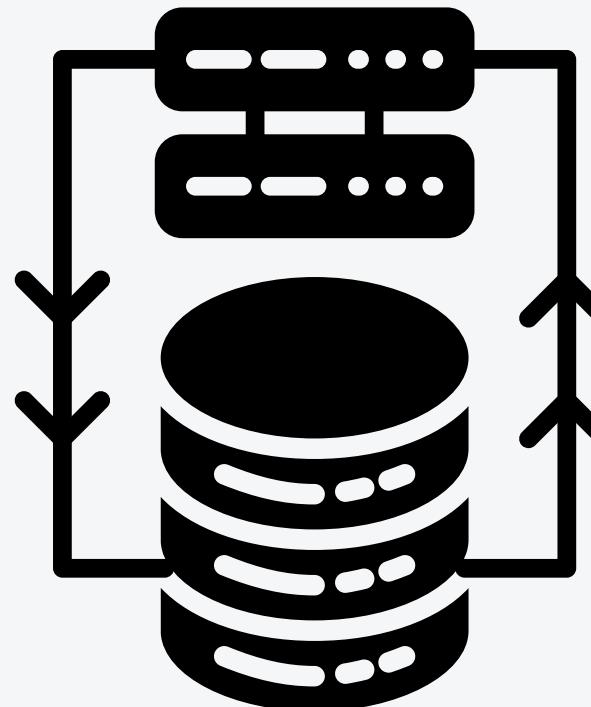
"Com milhões de músicas disponíveis em plataformas de streaming, como categorizar cada uma de forma eficiente e precisa?"



PROBLEMA

- ♪ Volume de músicas nas plataformas.
- ♪ Dificuldade de organização e busca.
- ♪ Necessidade de recomendação personalizada.

DADOS UTILIZADOS



**GTZAN Music
Genre Dataset**

GTZAN MUSIC GENRE DATASET

- **Número Total de Arquivos:**
 - **1.000 arquivos de áudio.**
- **Duração dos Áudios:**
 - **Cada arquivo de áudio tem exatamente 30 segundos.**
- **Número de Gêneros:**
 - **O dataset contém 10 gêneros, cada um com 100 músicas:**
 - **Blues, Classical, Country, Disco, Hip-hop, Jazz, Metal, Pop, Reggae, Rock**

METODOLOGIA



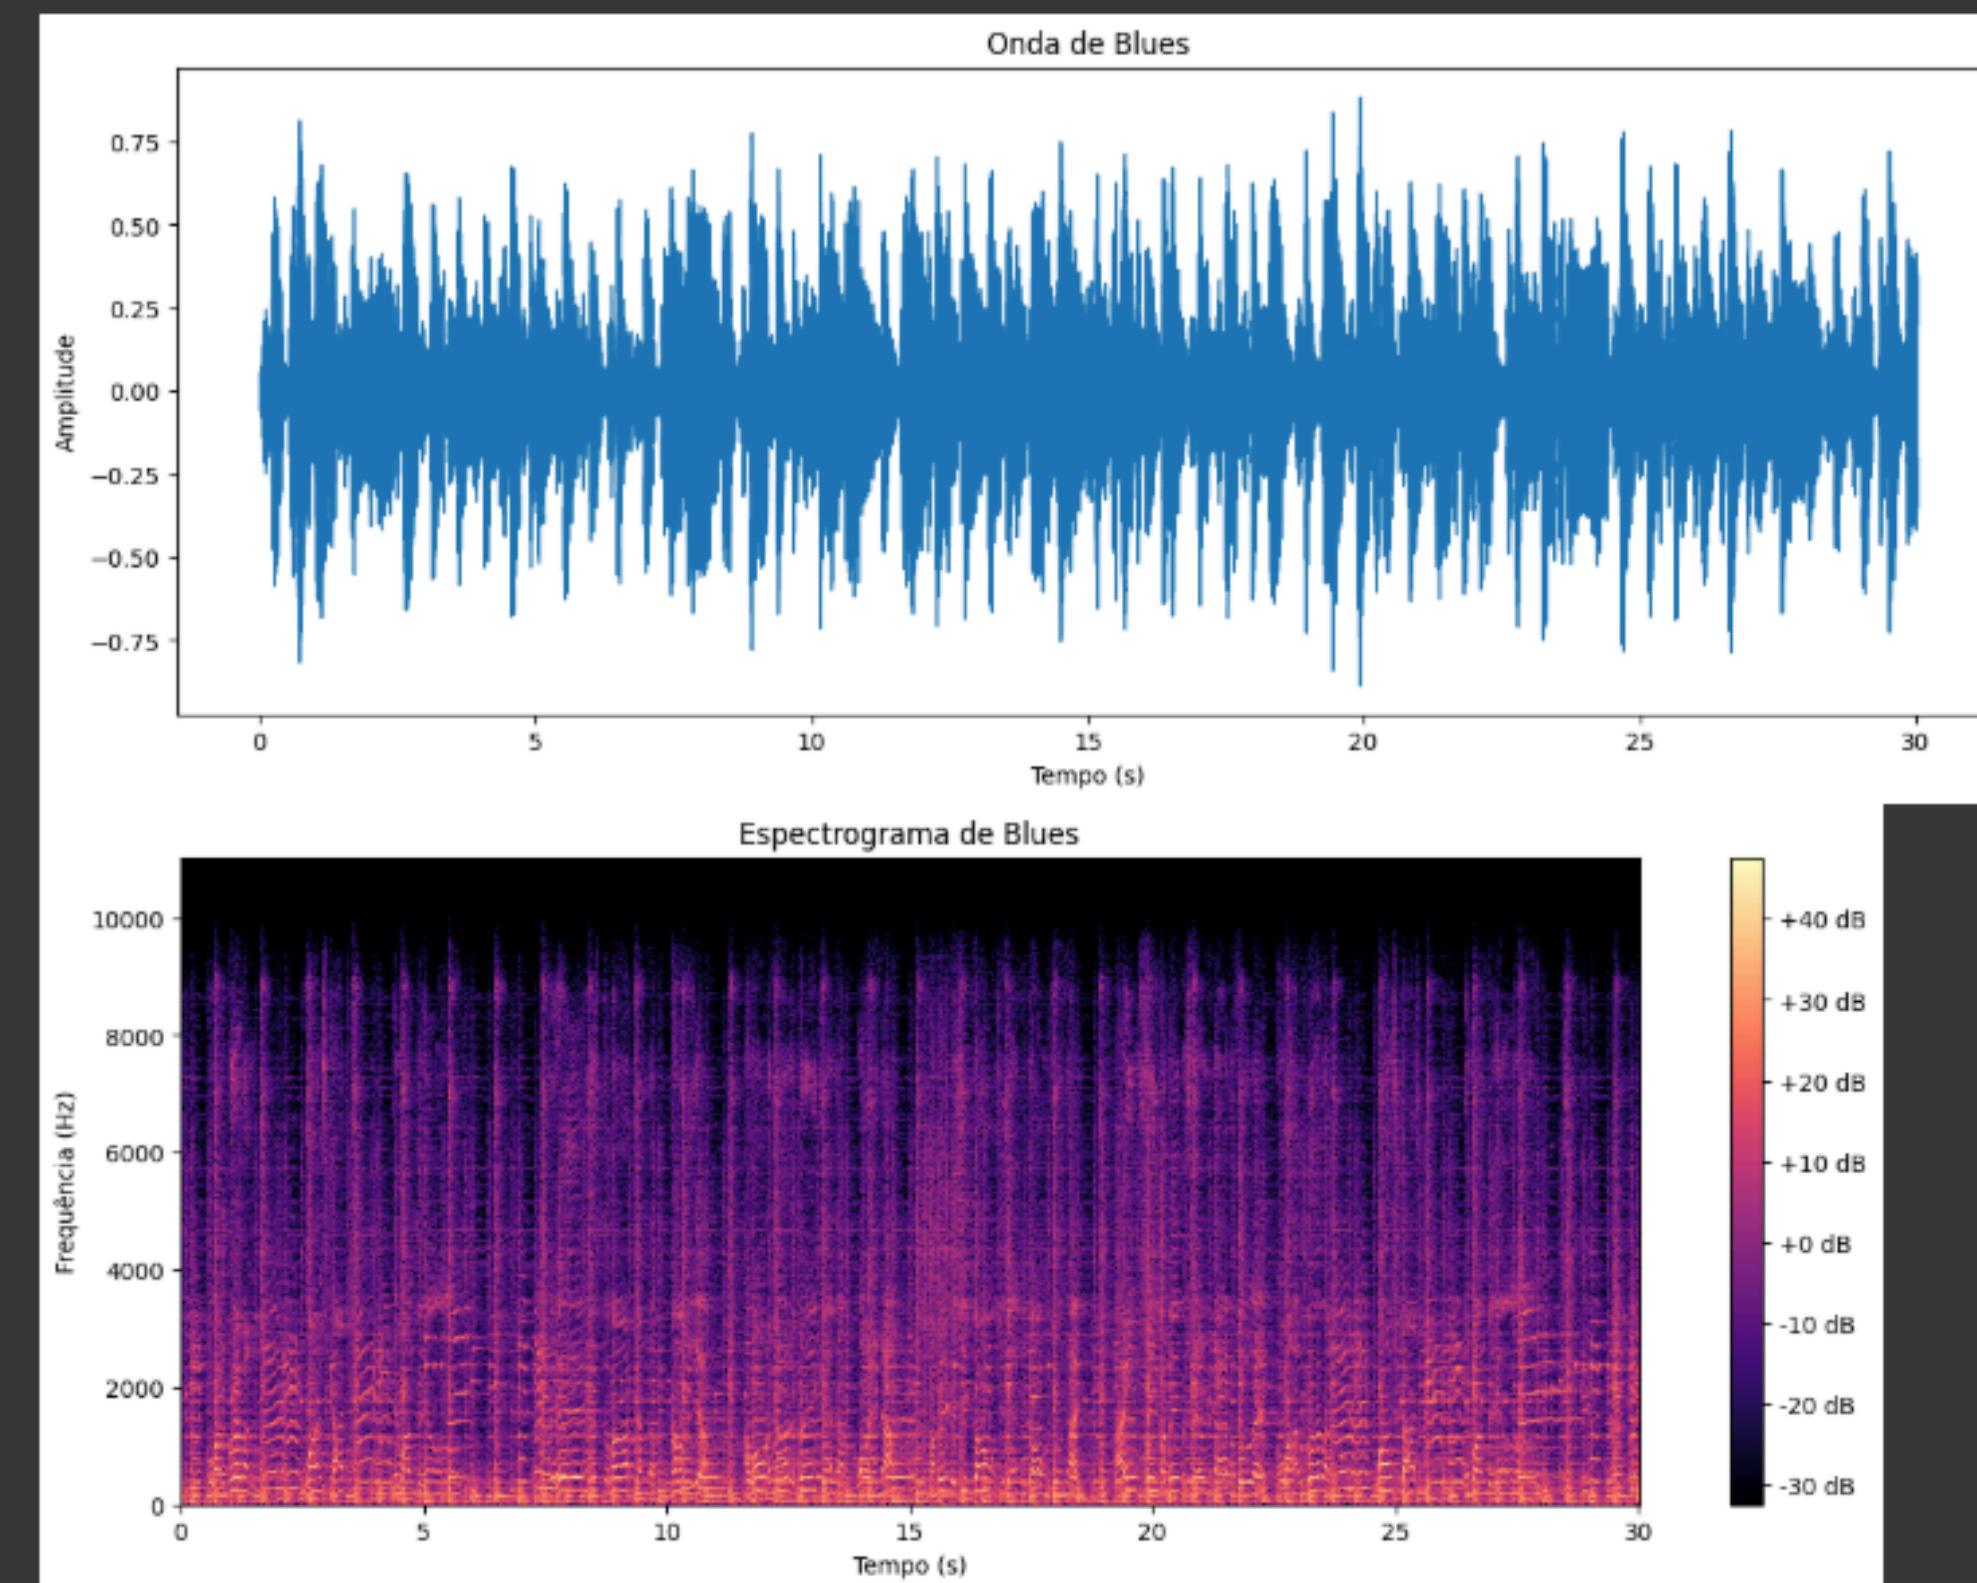
ANÁLISE EXPLORATÓRIA

**Verificação de balanceamento
(100 amostras/gênero).**

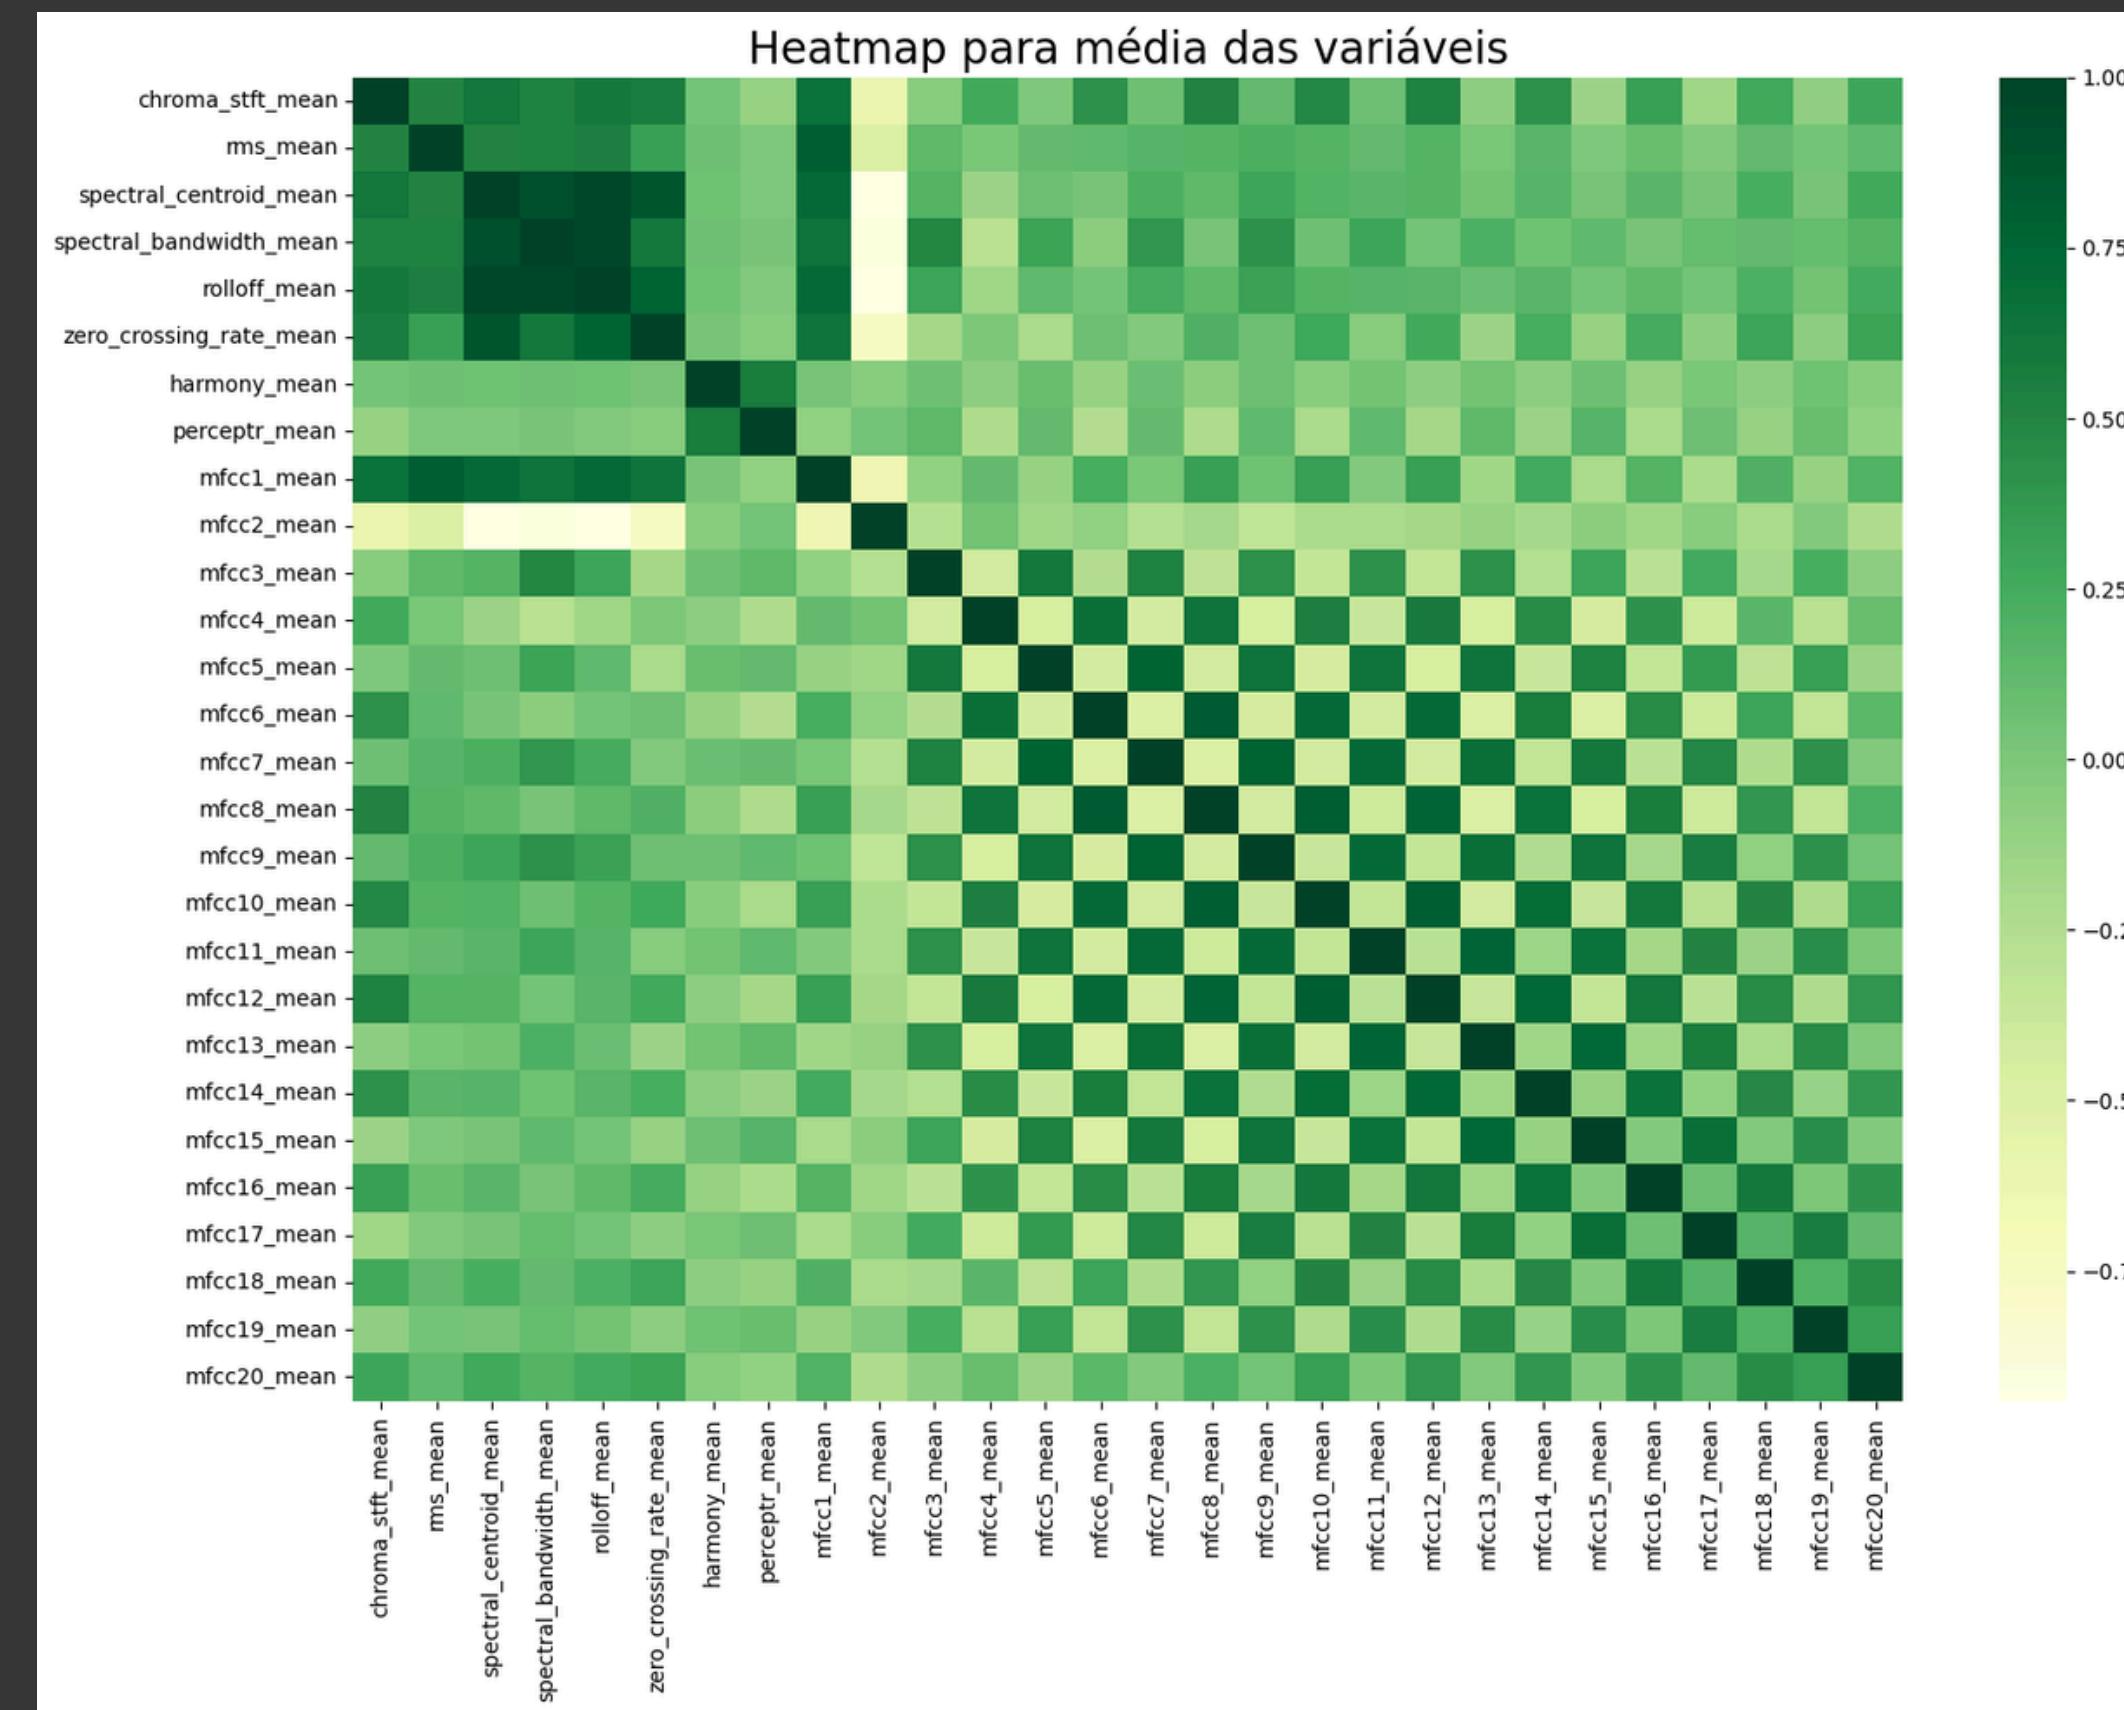
Formas de onda e espectrogramas com Librosa.

**Heatmap de correlação entre características
acústicas.**

GÊNERO BLUES



MATRIZ DE CORRELAÇÃO



PRÉ-PROCESSAMENTO

- Conversão das etiquetas de gênero:
 - LabelEncoder (scikit-learn)
- Remoção de colunas irrelevantes
- Normalização:
 - MinMaxScaler (intervalo comum para variáveis)
- Divisão em treino (70%) e teste (30%):
 - Função train_test_split



TREINAMENTO E TESTES

MODELOS DE CLASSIFICAÇÃO

- Random Forest
- CatBoost
- Gradient Boosting

RANDOM FOREST CLASSIFIER:

- **ACURACIA = 0.78**
- **F1-SCORE = 0.78**
- **TOP-3 = 0.96**

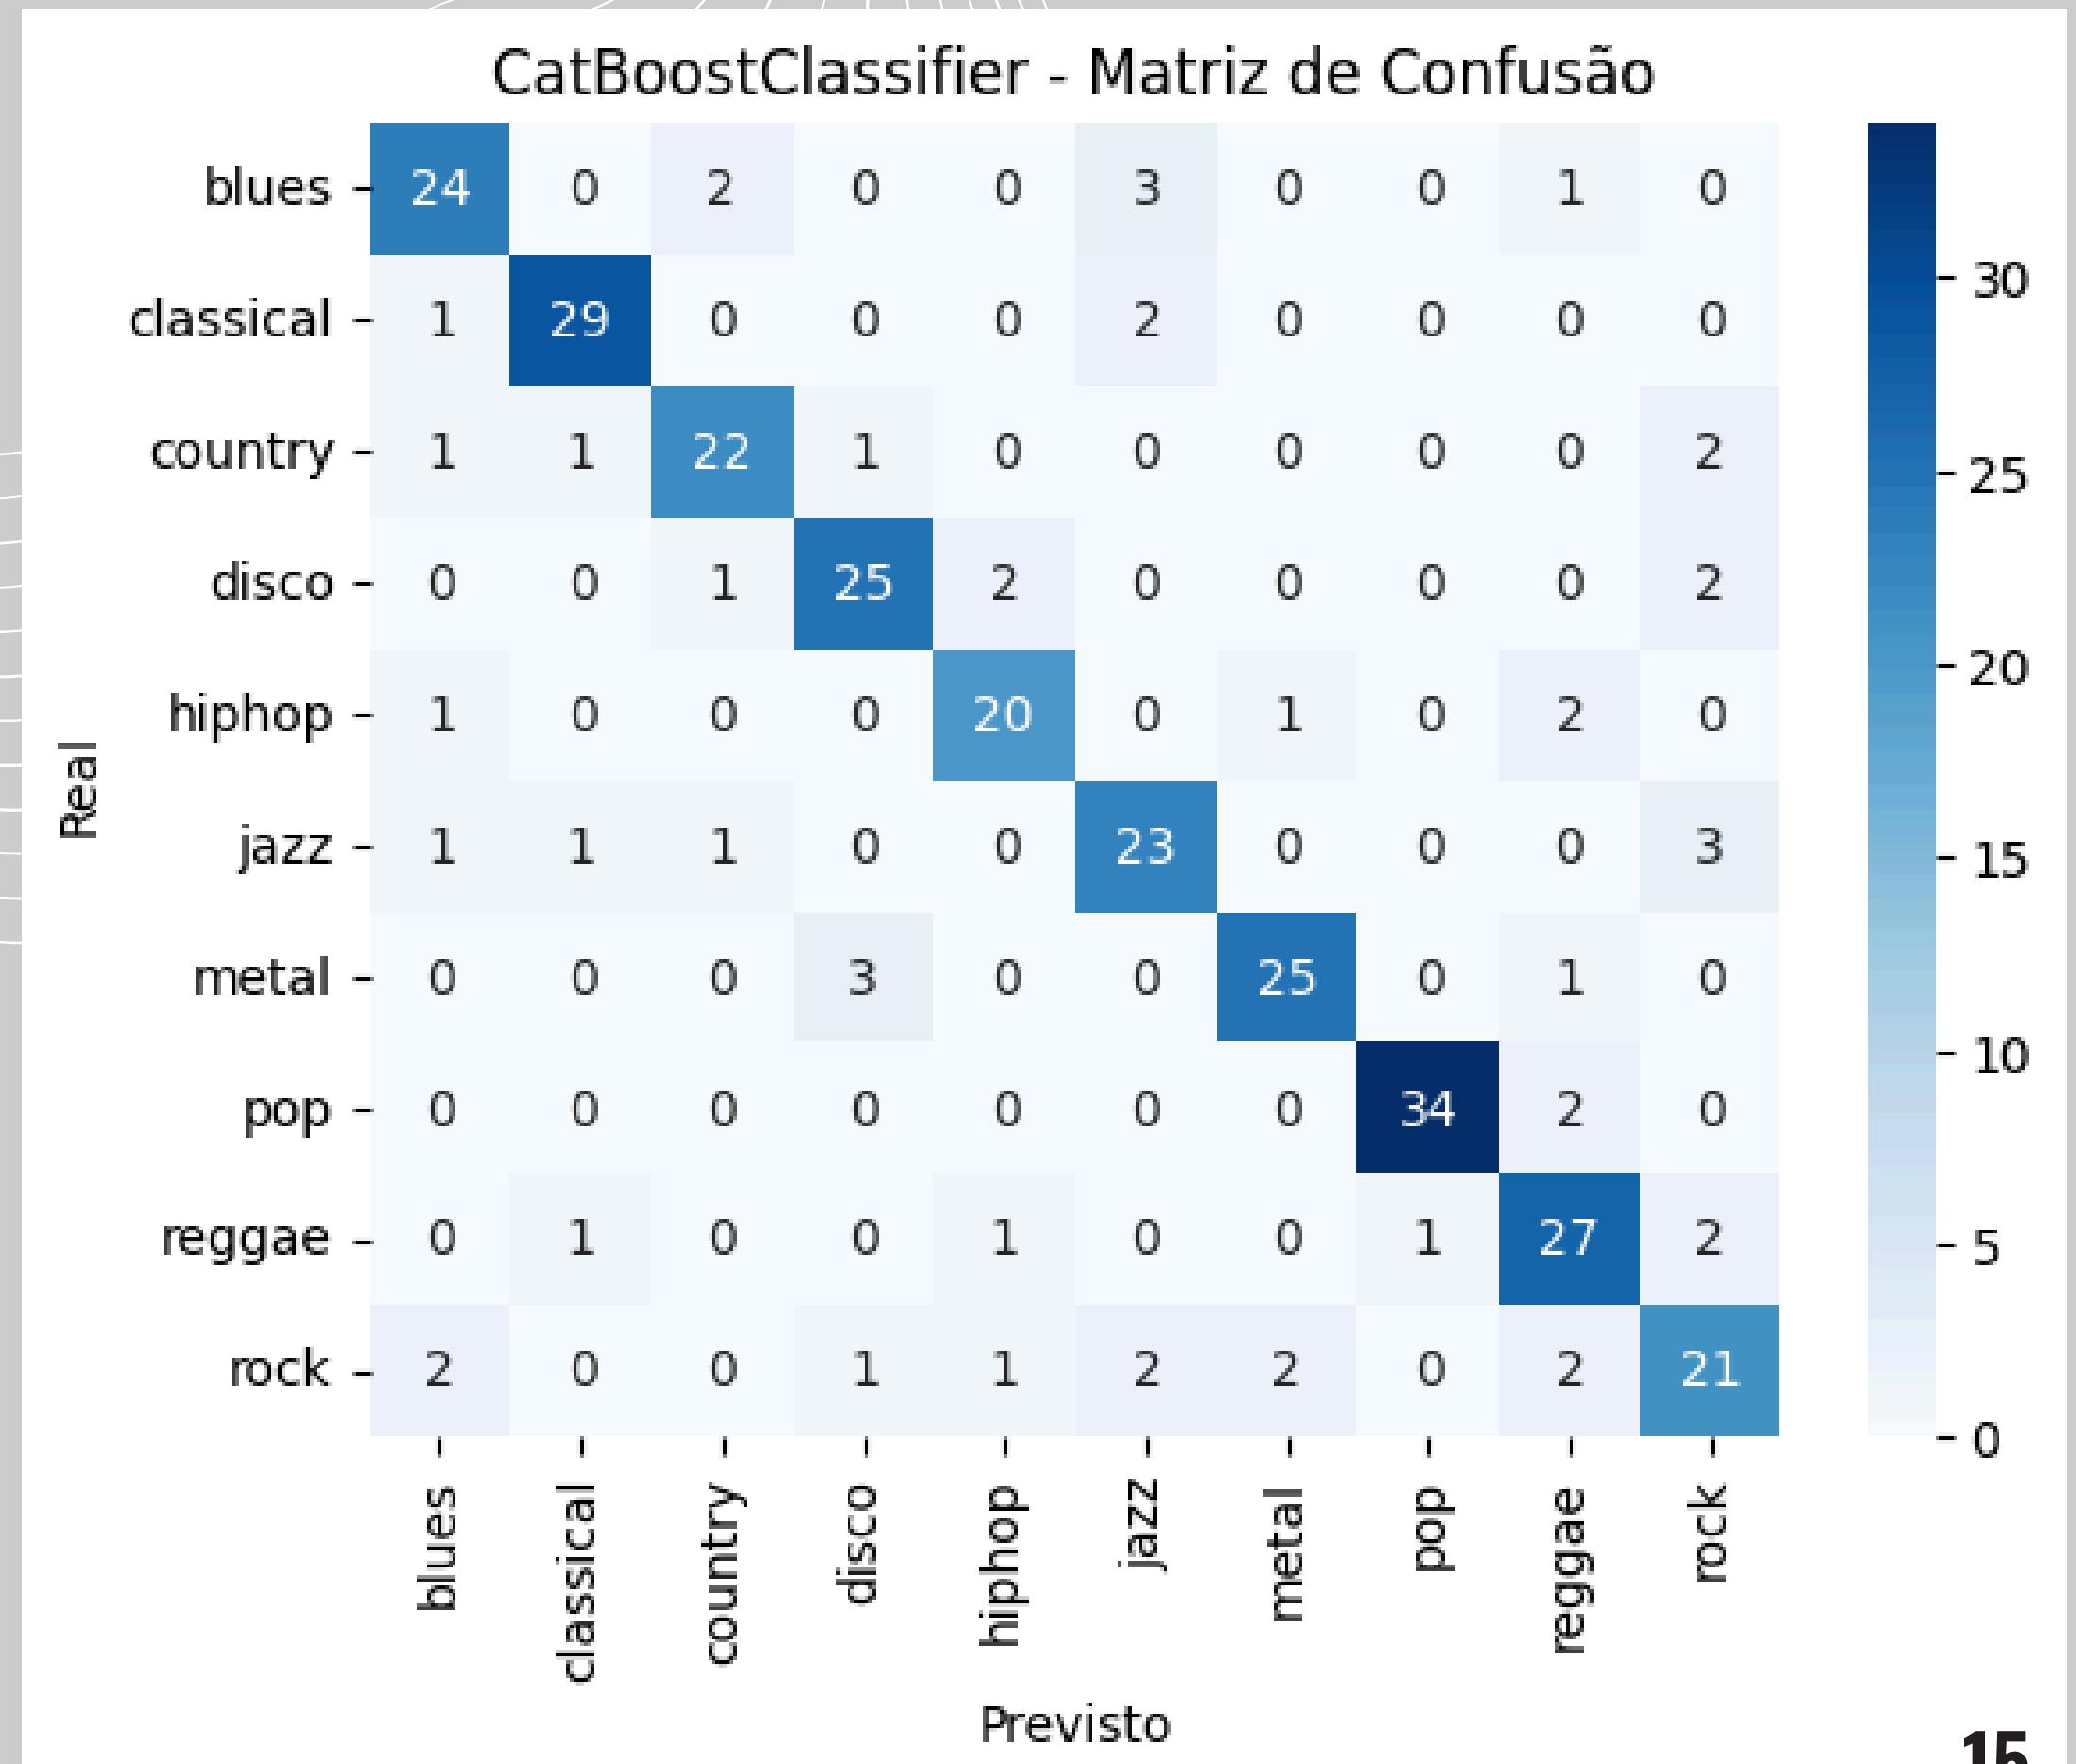


RandomForestClassifier - Matriz de Confusão

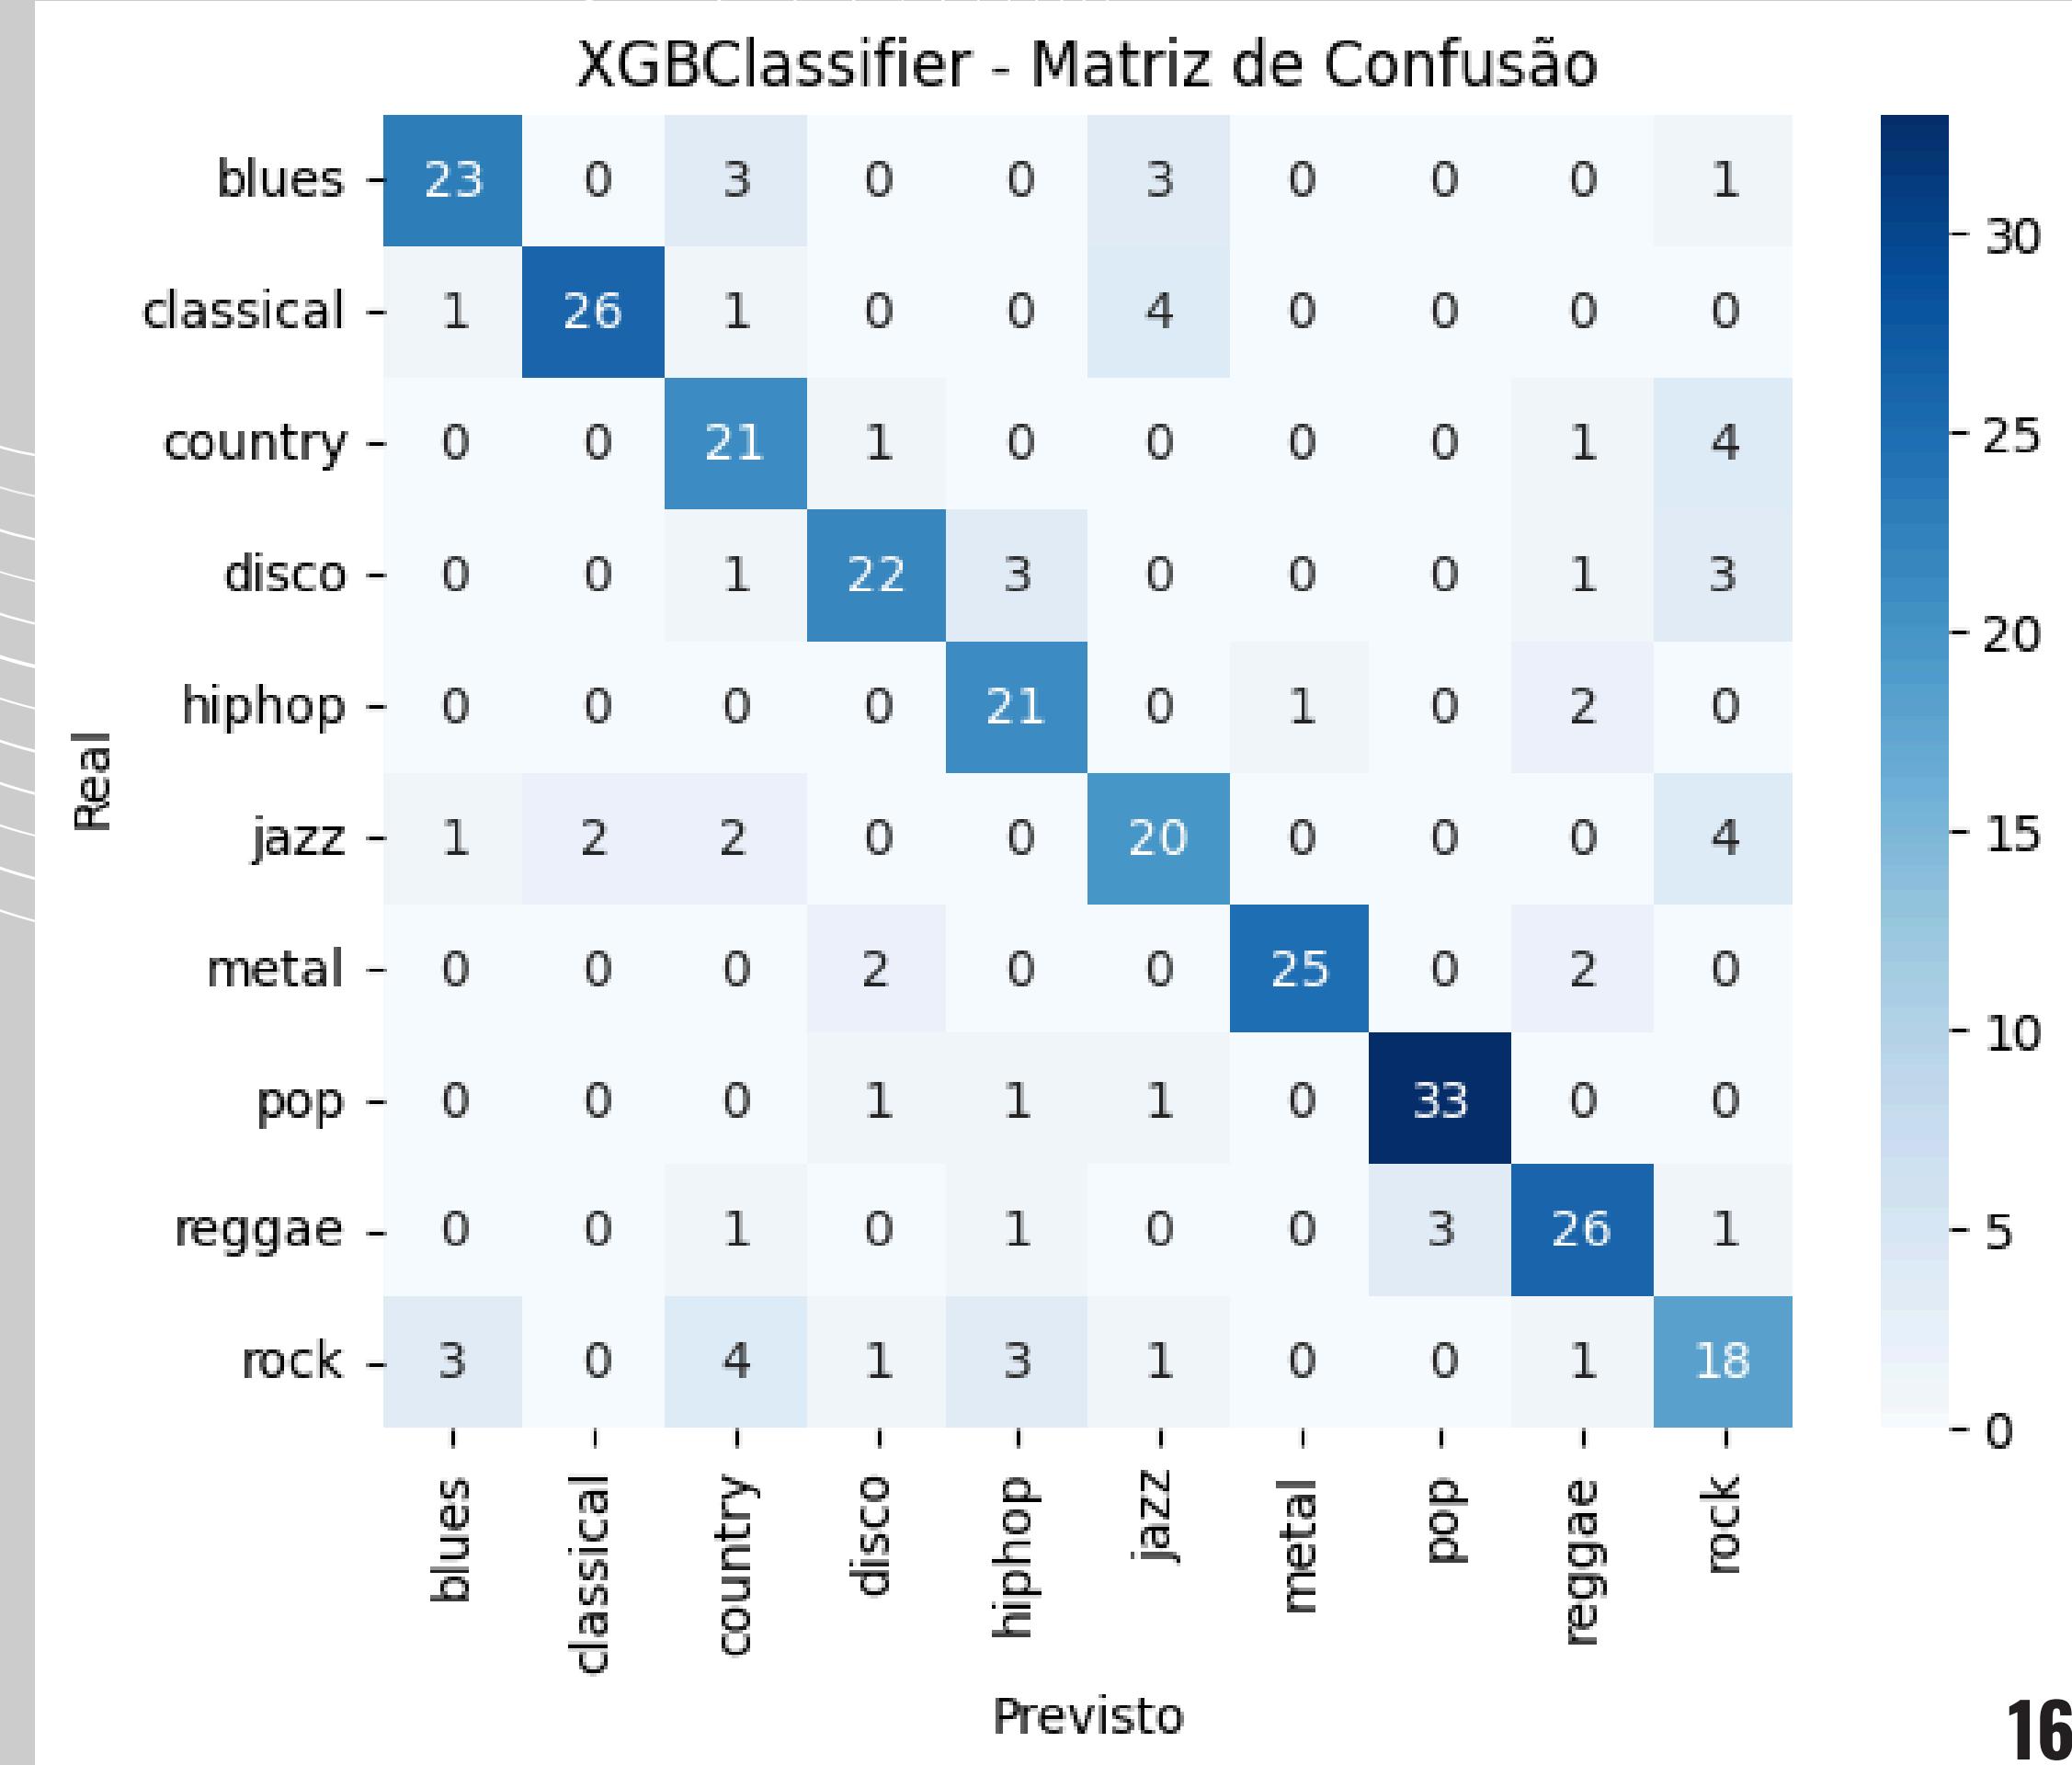
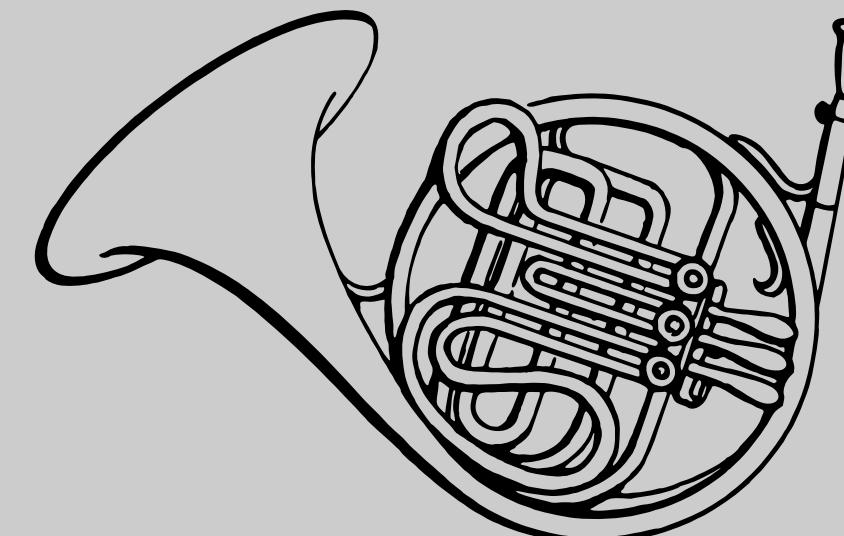
	Real									
	blues	classical	country	disco	hiphop	jazz	metal	pop	reggae	rock
blues	21	0	5	0	0	3	0	0	1	0
classical	1	28	0	0	0	3	0	0	0	0
country	1	0	17	0	1	2	0	1	1	4
disco	0	0	1	23	3	0	0	0	0	3
hiphop	1	0	0	0	20	0	1	0	2	0
jazz	0	2	3	0	0	21	0	0	0	3
metal	0	0	0	2	0	0	25	0	2	0
pop	0	0	0	0	0	0	0	32	4	0
reggae	0	0	1	0	0	0	0	1	29	1
rock	0	0	2	1	1	1	5	0	3	18

CATBOOST CLASSIFIER:

- **ACURACIA = 0.83**
- **F1 SCORE = 0.83**
- **TOP-3 = 0.96**



GRADIENT BOOSTING:
○ **ACURACIA = 0.78**
○ **F1 SCORE = 0.78**
○ **TOP 3 = 0.96**





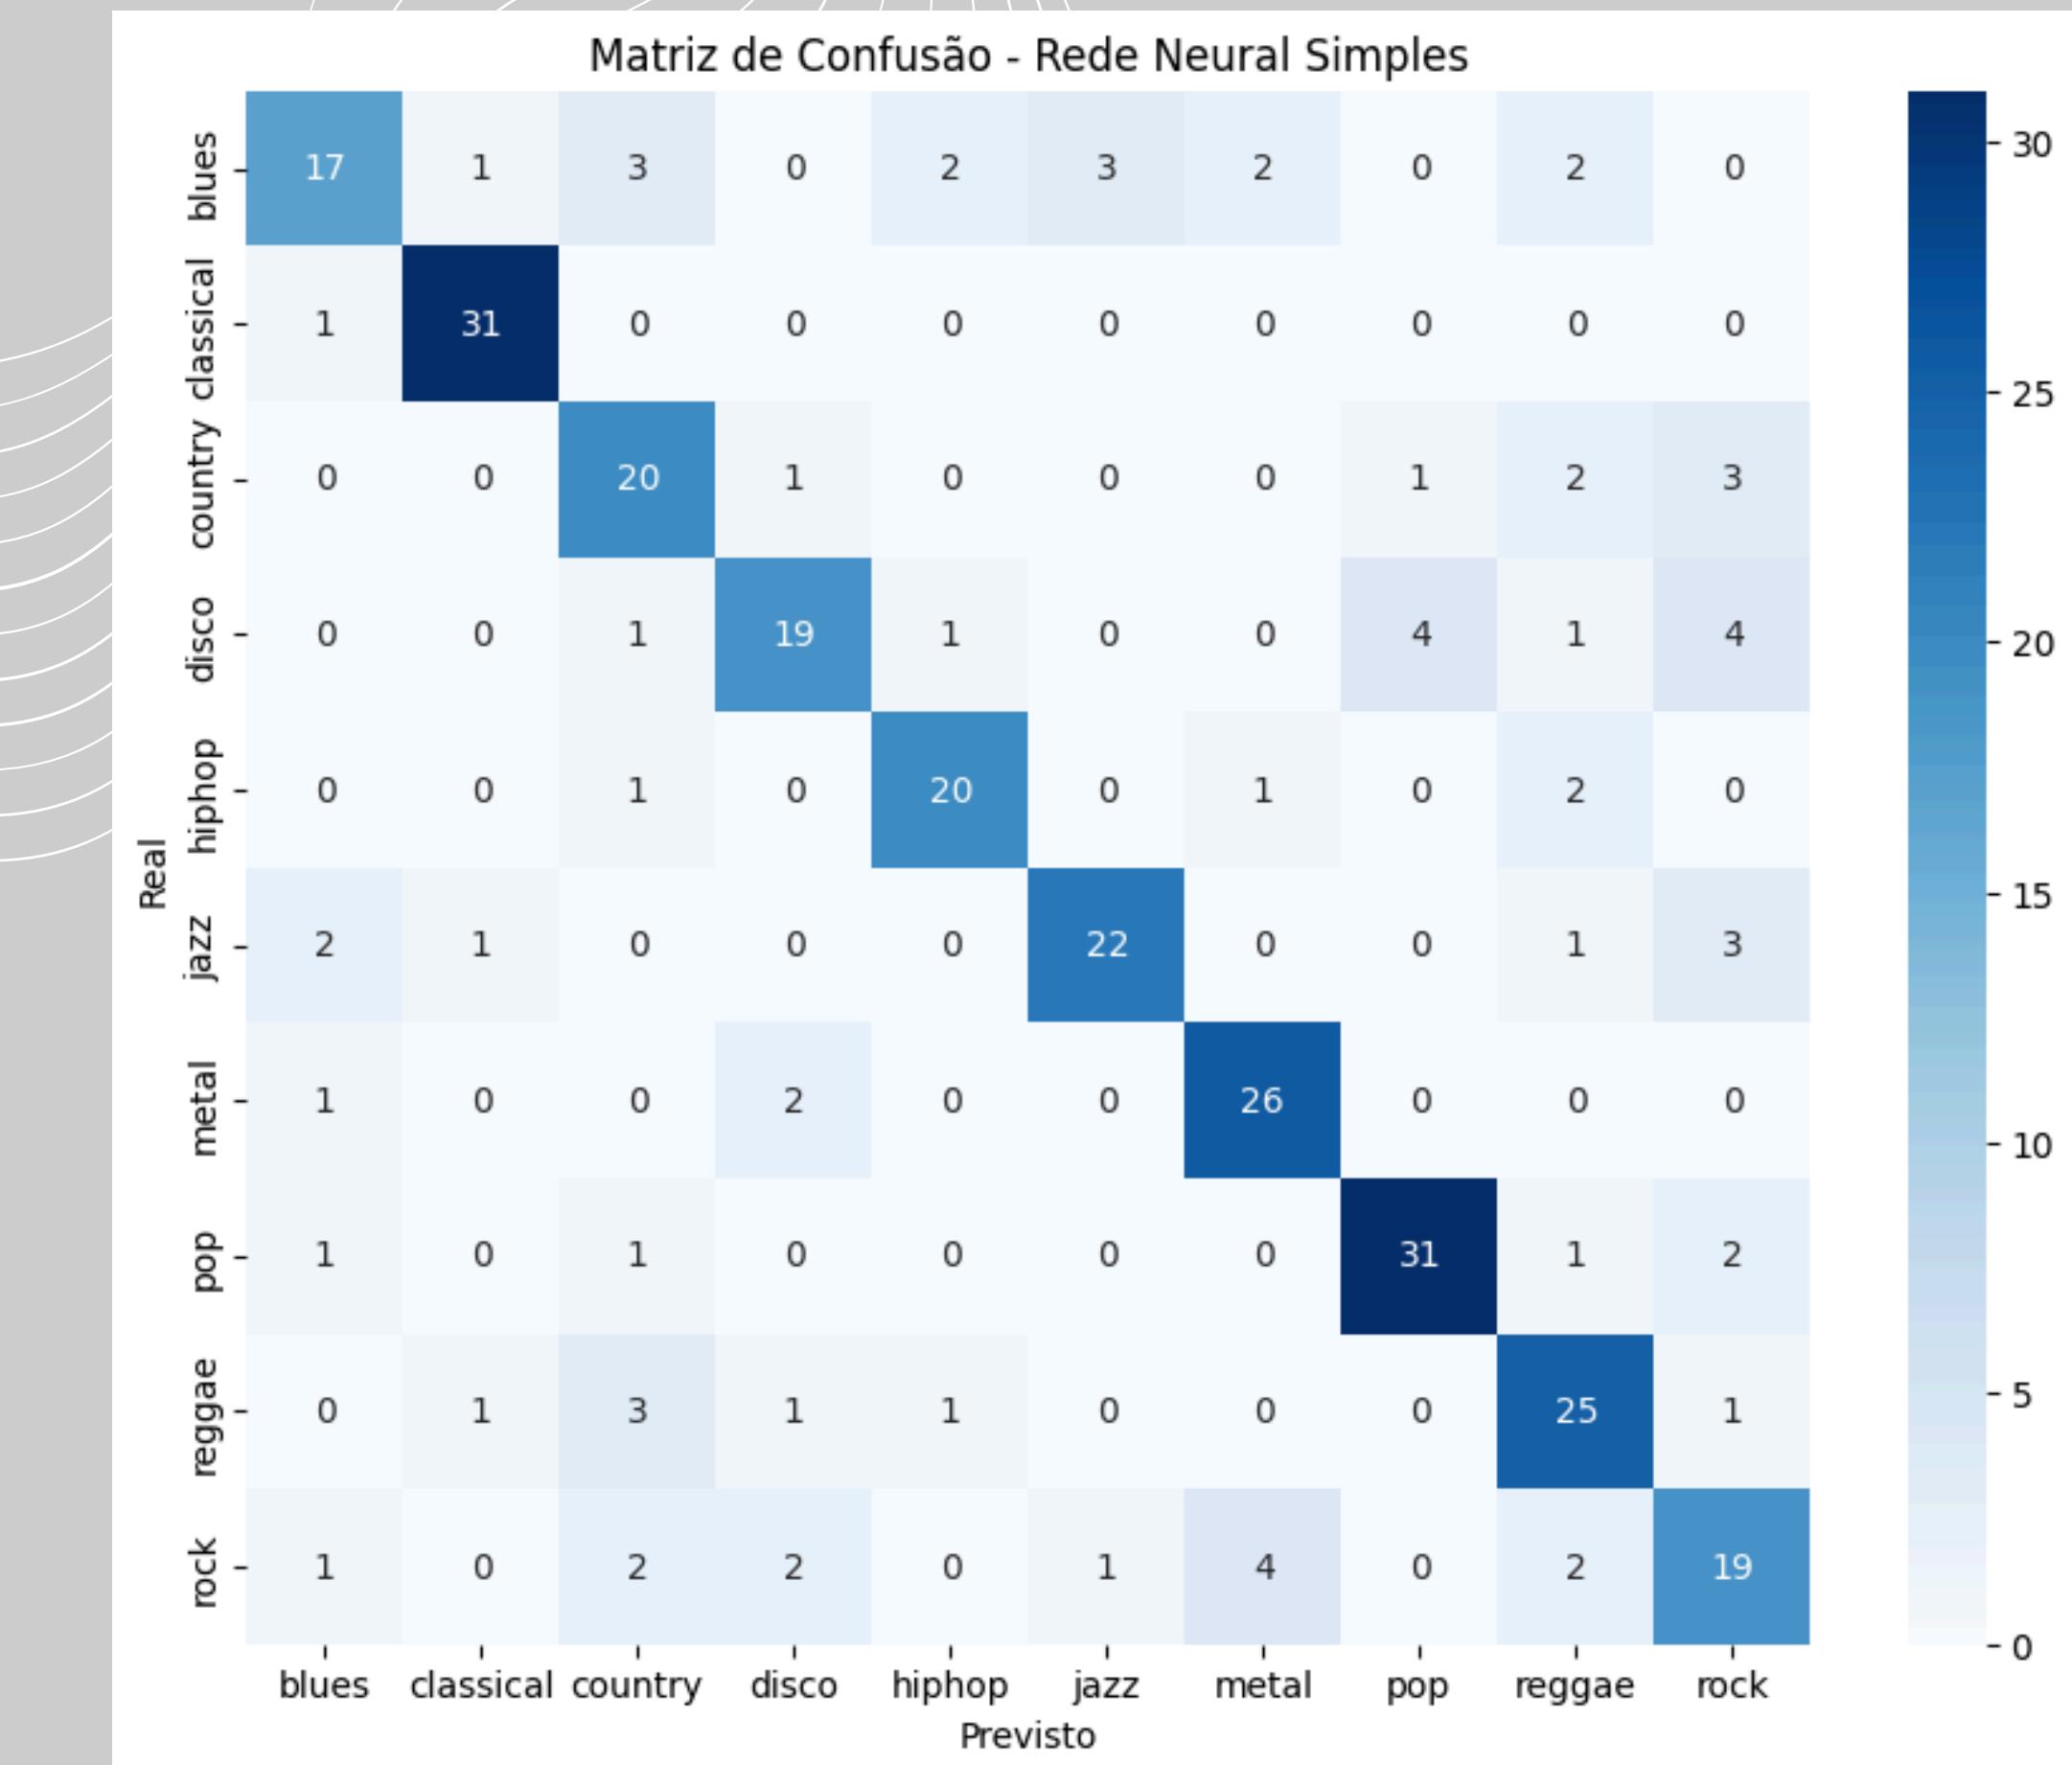
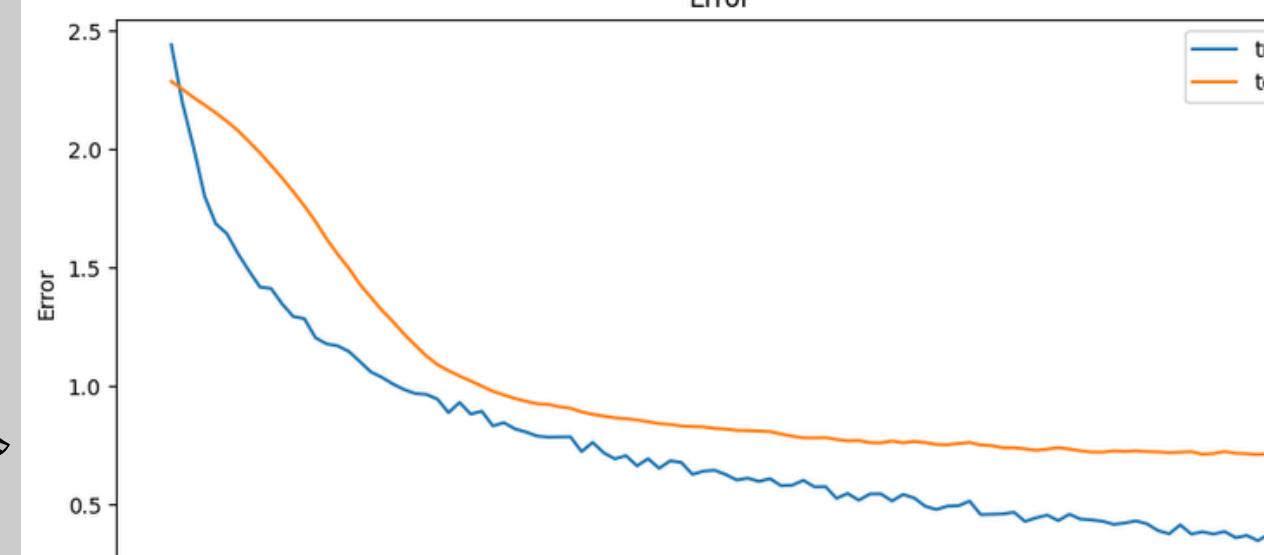
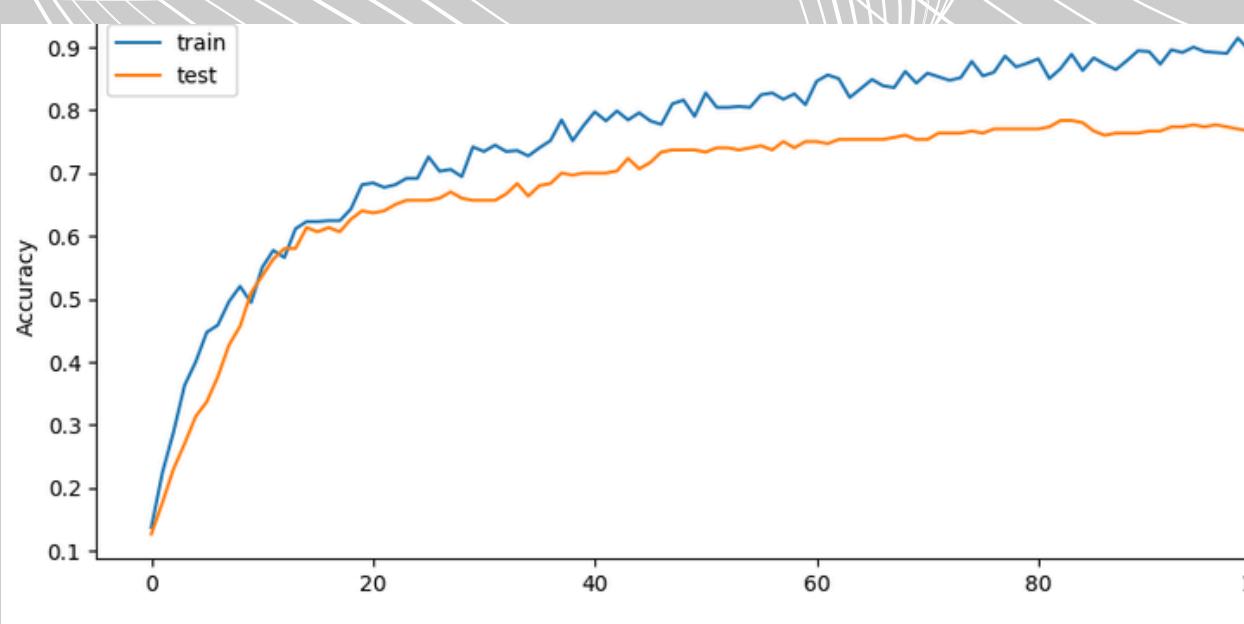
MODELO COM REDE NEURAL

- Camada Flatten.
- Primeira Camada Dense.
 - Função de ativação: ReLU (Retificação Linear).
- Segunda Camada Dense.
 - Função de ativação: ReLU.
- Camada de Saída.
 - Função de ativação: softmax para retornar probabilidades de cada classe.

REDE NEURAL:

- ACURACIA = 0.77

- MATRIZ DE CONFUSÃO:
 - ACURACIA = 0.77
 - F1 SCORE = 0.76
 - TOP 3 = 0.95



CONCLUSÕES

- CATBOOST É O MODELO MAIS EFICIENTE, SEGUIDO POR RANDOM FOREST, GRADIENT BOOSTING E REDE NEURAL RESPECTIVAMENTE.
- PADRÕES ÚTEIS PARA O TREINAMENTO DE MODELOS
- A IMPORTÂNCIA DA ESCOLHA DE CARACTERÍSTICAS E ALGORITMO
- LIMITAÇÕES NA BASE GTZAN
- FUTURAS PESQUISAS DEVEM EXPLORAR BASES MAIS AMPLAS E ARQUITETURAS AVANÇADAS, COMO CNNS

TABELA I.

RESULTADO DAS MÉTRICAS DE AVALIAÇÃO DOS MODELOS

Modelo	Acurácia	F1-Score (Macro)	Precisão Top-3
Random Forest	0,78	0,78	0,96
CatBoost	0,83	0,83	0,96
Gradient Boosting	0,78	0,78	0,96
Rede Neural	0,77	0,76	0,95



OBRIGADO

